

PHÁT TRIỂN HỆ THỐNG GIÁM SÁT CHẤT LƯỢNG RAU HỌ CẢI ỨNG DỤNG IoT VÀ AI

Trần Đức Vũ¹, Bùi Đức Hiếu¹, Tôn Long Phước^{1*}

¹Khoa Công nghệ Thông tin, Trường Đại học Công nghiệp TP. HCM

*tonlongphuoc@iuh.edu.vn

Abstract—Cruciferous vegetables play an essential role in Vietnamese agriculture, providing vital nutrients for consumers and contributing significantly to the agricultural economy. However, traditional methods for monitoring crop quality and detecting diseases remain limited in both accuracy and efficiency. This study proposes a comprehensive monitoring system that integrates Internet of Things (IoT) and Artificial Intelligence (AI) technologies to track environmental conditions and detect diseases in cruciferous crops. The system employs Node.js for the backend, ReactJS and React Native for user interfaces, and MongoDB for data storage using the bucket pattern and vector database models. Notably, two parallel AI architectures are implemented: the YOLO model for automatic disease detection from periodic images, and a Retrieval-Augmented Generation (RAG) framework combined with VGG16 for providing detailed crop condition analysis. Experimental results on 100 samples achieved 90% accuracy, demonstrating the system's effectiveness. This research offers a practical solution to help farmers accurately monitor environmental conditions, detect diseases early, and make timely cultivation decisions, while also enhancing transparency for consumers regarding the origin and quality of agricultural products.

Index Terms—IoT, YOLO, RAG, agricultural monitoring, crop disease detection, cruciferous vegetables, deep learning.

Tóm tắt — Các loại rau thuộc họ cải đóng vai trò quan trọng trong nông nghiệp Việt Nam, cung cấp nhiều dưỡng chất thiết yếu cho người tiêu dùng và góp phần đáng kể vào kinh tế nông nghiệp. Tuy nhiên, các phương pháp truyền thống trong việc giám sát chất lượng cây trồng và phát hiện sâu bệnh vẫn còn hạn chế về độ chính xác và hiệu quả. Nghiên cứu này đề xuất một hệ thống giám sát toàn diện, tích hợp công nghệ Internet vạn vật (IoT) và Trí tuệ nhân tạo (AI) để theo dõi điều kiện môi trường và phát hiện bệnh trên cây trồng họ cải. Hệ thống sử dụng Node.js cho backend, ReactJS và React Native cho giao diện người dùng, và MongoDB để lưu trữ dữ liệu theo mô hình bucket pattern và cơ sở dữ liệu vector. Hai kiến trúc AI song song được triển khai: mô hình YOLO để tự động phát hiện bệnh từ hình ảnh định kỳ, và framework RAG kết hợp với VGG16 để cung cấp phân tích chi tiết về tình trạng cây trồng. Kết quả thực nghiệm trên 100 mẫu đạt độ chính xác 90%, chứng minh hiệu quả của hệ thống. Nghiên cứu mang đến giải pháp thực tiễn hỗ trợ nông dân giám sát môi trường chính xác, phát hiện sớm bệnh hại và đưa ra quyết định canh tác kịp thời, đồng thời tăng tính minh bạch cho người tiêu dùng về nguồn gốc và chất lượng nông sản.

Từ khóa — IoT, YOLO, RAG, giám sát nông nghiệp, phát hiện bệnh cây trồng, rau họ cải, học sâu.

I. GIỚI THIỆU

A. Đặt vấn đề

Họ cải như cải bắp, súp lơ, bông cải xanh và cải thảo là nhóm rau quan trọng của nông nghiệp Việt Nam nhờ diện tích canh tác lớn và giá trị dinh dưỡng cao. Tuy nhiên, các loại rau này rất nhạy cảm với điều kiện môi trường và dễ bị ảnh hưởng bởi nhiệt độ, độ ẩm và bệnh hại. Việc giám sát truyền thống dựa trên quan sát thủ công đòi hỏi nhiều kinh nghiệm, tốn thời gian và thiếu độ chính xác, dẫn đến phát hiện bệnh muộn và giảm năng suất [1], [2].

Trong bối cảnh Cách mạng công nghiệp 4.0, IoT cho phép thu thập dữ liệu môi trường liên tục, trong khi AI hỗ trợ phân tích và đưa ra quyết định canh tác thông minh [3]–[5]. Sự kết hợp IoT–AI mở ra hướng tiếp cận tự động hóa toàn diện trong giám sát chất lượng cây trồng.


B. Tổng quan nghiên cứu liên quan

Các nghiên cứu đã chứng minh hiệu quả của IoT và AI trong nông nghiệp thông minh: Nghiên cứu của Siddiquee et al. [6] ứng dụng mạng nơ-ron tích chập (CNN) để phát hiện và định lượng rau củ với độ chính xác trên 90%. Các mô hình YOLO đã chứng minh hiệu quả vượt trội trong phát hiện bệnh cây trồng. Nghiên cứu của Sharma et al. [7] cho thấy YOLOv4 đạt độ chính xác 98% với mAP 98% trong phát hiện bệnh trên lá cây ăn quả. Liu và Wang [8] phát triển mô hình YOLO V3 cải tiến để phát hiện bệnh và sâu hại trên cà chua với mAP đạt 95.57%.

II. PHƯƠNG PHÁP NGHIÊN CỨU

A. Kiến trúc hệ thống

Hệ thống có kiến trúc ba tầng: tầng thiết bị sử dụng node cảm biến ESP32-S3 thu thập dữ liệu môi trường, điều khiển thiết bị ngoại vi và truyền về backend qua HTTP; tầng xử lý chạy trên Node.js để chuẩn hóa dữ liệu, lưu MongoDB và chuyển lệnh điều khiển, đồng thời có pipeline xử lý ảnh riêng với Flask vector hóa ảnh lưu vào Mongo Vector DB, YOLO phát hiện bệnh hại, sau đó kết hợp kết quả với thông tin ngữ cảnh qua GPT theo kỹ thuật RAG; tầng ứng dụng cung cấp giao diện web và di động cho phép theo dõi dữ liệu thời gian thực, nhận cảnh báo qua Firebase, xem chẩn đoán và điều khiển từ xa.



Luồng hoạt động 1: Thu thập và lưu trữ dữ liệu môi trường

- 1) Thiết bị IoT thu thập dữ liệu từ các cảm biến theo chu kỳ định kỳ.
- 2) Dữ liệu được gửi đến backend Node.js qua giao thức HTTP.
- 3) Dữ liệu được truy vấn và hiển thị dưới dạng biểu đồ trên giao diện web/mobile.

Luồng hoạt động 2: Phát hiện bệnh tự động (YOLO)

- 1) Thiết bị IoT tự động chụp ảnh cây trồng theo lịch định kỳ mỗi tuần.
- 2) Ảnh được gửi đến backend Node.js.
- 3) Backend chuyển ảnh đến mô hình YOLO để phát hiện các vùng bị bệnh.
- 4) Kết quả phát hiện được gửi đến OpenAI để tạo báo cáo mô tả chi tiết.
- 5) Báo cáo được lưu vào database và thông báo cho chủ nông trại.

Luồng hoạt động 3: Tư vấn bệnh cây (RAG Pipeline)

- 1) Người dùng tải lên ảnh cây trồng nghi ngờ bị bệnh qua giao diện.
- 2) Backend Node.js chuyển ảnh đến Python backend.
- 3) Python backend sử dụng VGG16 để trích xuất feature vector (4096 chiều) từ ảnh.
- 4) Vector được so sánh với các vector trong MongoDB để tìm các mẫu bệnh tương tự.
- 5) Top-k kết quả tương tự nhất được truy xuất cùng với mô tả bệnh.
- 6) Dữ liệu này được đưa vào OpenAI LLM để tạo câu trả lời tư vấn chi tiết.
- 7) Kết quả được trả về cho người dùng với giải thích, nguyên nhân và biện pháp xử lý.

Bảng I: Các module chức năng chính

Module chủ nông trại	Module thiết bị IoT	Module người dùng cuối
Quản lý thiết bị IoT: Thêm, xóa, cấu hình các thiết bị cảm biến và actuator.	Thu thập dữ liệu: Đọc giá trị từ các cảm biến DHT11, ES-SOIL-7-IN-1, light sensor.	Quét mã QR: Tra cứu thông tin nông sản bằng mã QR trên bao bì.
Dashboard giám sát: Hiển thị theo thời gian thực và lịch sử dữ liệu môi trường dưới dạng biểu đồ.	Chụp ảnh định kỳ: Camera tự động chụp ảnh theo lịch.	Xem lịch sử: Thông tin về nguồn gốc, nông trại, điều kiện canh tác.
Quản lý nông sản: Tạo batch sản phẩm, gắn mã QR, cập nhật thông tin canh tác.	Gửi dữ liệu: Truyền dữ liệu về backend qua WiFi/4G.	Xem dữ liệu môi trường: Nhiệt độ, độ ẩm, pH, N-P-K trong quá trình trồng.
Nhận cảnh báo: Thông báo tự động khi phát hiện bệnh hoặc điều kiện môi trường bất thường.	Điều khiển actuator: Nhận lệnh từ backend để bật/tắt đèn, bơm nước.	Xem hình ảnh: Ảnh thực tế của cây trồng tại các giai đoạn khác nhau.
Xem báo cáo AI: Truy cập kết quả phát hiện bệnh từ YOLO và tư vấn từ RAG.		
Kiểm tra bệnh: Upload ảnh lá để nhận tư vấn về tình trạng cây trồng.		

B. Công nghệ liên quan

Trong bối cảnh Cách mạng công nghiệp 4.0, việc ứng dụng các công nghệ Internet of Things (IoT) và Trí tuệ nhân tạo (AI) trong nông nghiệp đã tạo nên bước chuyển đổi mạnh mẽ hướng đến mô hình nông nghiệp chính xác. Công nghệ IoT cho phép giám sát liên tục các thông số môi trường như nhiệt độ, độ ẩm, pH, ánh sáng và hàm lượng dinh dưỡng thông qua mạng cảm biến không dây, giúp hình thành các hệ thống tự động hóa quy trình thu thập và phân tích dữ liệu nhằm phát hiện sớm bất thường trong canh tác [1], [4], [5].

Song song đó, AI và học sâu (Deep Learning) đóng vai trò cốt lõi trong việc phân tích hình ảnh nông nghiệp, đặc biệt trong nhận diện bệnh lá và phân loại tình trạng cây trồng. Các mô hình học sâu như YOLO, EfficientNet và ResNet đã chứng minh hiệu quả vượt trội trong phát hiện bệnh trên rau màu [8]–[10]. Việc tích hợp YOLOv8 và các phiên bản cao hơn với cơ chế xử lý ảnh thời gian thực giúp nâng cao độ chính xác và tốc độ chẩn đoán bệnh lý thực vật. Bên cạnh đó, kiến trúc Retrieval-Augmented Generation (RAG), được đề xuất bởi [11], cho phép kết hợp giữa truy xuất tri thức và sinh ngôn ngữ tự nhiên, tạo nên nền tảng tư vấn nông nghiệp thông minh có khả năng cung cấp khuyến nghị chuyên sâu và giàu ngữ cảnh.

Các tiến bộ trong cơ sở dữ liệu vector như MongoDB Atlas Vector Search và FAISS đã tối ưu hóa khả năng truy vấn tương tự trong không gian đa chiều, rút ngắn thời gian phản hồi trong quá trình tìm kiếm và phân tích dữ liệu hình ảnh [12], [13]. Cùng với đó, các công nghệ triển khai cloud-native như Docker, AWS EC2, Cloudflare CDN và Nginx Load Balancer đảm bảo khả năng mở rộng linh hoạt, tính ổn định cao và độ sẵn sàng hệ thống vượt trội, phù hợp cho các ứng dụng nông nghiệp thông minh ở quy mô lớn.

Tổng thể, sự kết hợp giữa IoT, AI, cơ sở dữ liệu vector và công nghệ đám mây đã hình thành nên một hệ sinh thái giám sát và phân tích nông nghiệp toàn diện, cho phép thu thập, xử lý, suy luận và tư vấn trong thời gian thực, hướng đến mục tiêu phát triển nông nghiệp bền vững, chính xác và hiện đại hóa nông thôn Việt Nam


C. Thu thập dữ liệu

Hệ thống thu thập dữ liệu được xây dựng trên nền tảng vi điều khiển **ESP32-S3**, đóng vai trò trung tâm trong việc thu thập, xử lý và truyền dữ liệu cảm biến lên máy chủ. Các phần tử phần cứng chính bao gồm:

- **Cảm biến DHT11:** Dùng để đo nhiệt độ và độ ẩm không khí trong môi trường trồng rau. Tín hiệu dữ liệu được kết nối với chân GPIO14 của ESP32-S3.
- **Cảm biến ánh sáng:** Thu thập cường độ chiếu sáng xung quanh, kết nối với chân ADC GPIO19, giúp đánh giá điều kiện quang hợp của cây.
- **Cảm biến đất N-P-K:** Đo các thông số độ ẩm đất, pH và nồng độ dinh dưỡng N–P–K. Dữ liệu được truyền qua giao thức RS485 thông qua module chuyển đổi RS485–TTL, kết nối với UART (TX=45, RX=38) của ESP32-S3.
- **Module Relay 2 kênh:** Cho phép điều khiển đèn chiếu sáng và bơm nước. Hai kênh điều khiển được nối lần

lượt tới các chân GPIO IN1 và GPIO IN2 của vi điều khiển.

- **Nguồn cấp:** Cảm biến RS485 và bơm sử dụng nguồn 12VDC, trong khi ESP32-S3 và relay sử dụng nguồn 5VDC.
- **Nút nhấn:** Tích hợp trên chân GPIO0, cho phép người dùng kích hoạt chế độ cấu hình Wi-Fi khi nhấn giữ trong 1,5 giây.



Hình 3: Kiến trúc tổng thể hệ thống giám sát và phân tích chất lượng rau họ cải.

Hệ thống vận hành theo cơ chế tự động, trong đó vi điều khiển **ESP32-S3** đóng vai trò trung tâm, đảm nhiệm việc thu thập dữ liệu, truyền thông và điều khiển thiết bị. Sau khi kết nối Wi-Fi, ESP32-S3 định kỳ đọc dữ liệu từ các cảm biến DHT11, cảm biến ánh sáng và cảm biến đất N-P-K để thu thập các thông số về nhiệt độ, độ ẩm, pH, ánh sáng và hàm lượng dinh dưỡng. Các dữ liệu thu được được gửi lên máy chủ để lưu trữ và phân tích, từ đó hệ thống có thể đưa ra quyết định điều khiển như bật/tắt đèn chiếu sáng hoặc bơm nước thông qua module relay. Quá trình này diễn ra liên tục, giúp duy trì môi trường canh tác ổn định và phù hợp cho sự phát triển của rau họ cải. Ngoài ra, thiết bị còn có khả năng chụp ảnh định kỳ và truyền về máy chủ để mô hình AI phân tích, hỗ trợ phát hiện sớm các dấu hiệu bệnh hại, góp phần nâng cao hiệu quả giám sát và chất lượng nông sản.

Bảng II: Dữ liệu môi trường cần thu thập

Điều kiện không khí	Điều kiện đất	Hình ảnh cây trồng
Nhiệt độ không khí: DHT11 ($\pm 0.5^\circ\text{C}$) Độ ẩm không khí: DHT11 ($\pm 2\%$) Cường độ ánh sáng: Light Sensor V2.1	Nhiệt độ đất: ES-SOIL-7-IN-1 Độ ẩm đất: ES-SOIL-7-IN-1 (%) pH đất: ES-SOIL-7-IN-1 (0–14) N-P-K: ES-SOIL-7-IN-1 (mg/kg)	Dữ liệu ảnh cho YOLO: - Ảnh chụp tự động hàng tuần (thứ 2). - Phát hiện tự động vùng lá bệnh. Dữ liệu ảnh cho RAG: - Ảnh upload thủ công từ người dùng. - Dùng cho tư vấn chi tiết tình trạng bệnh.
Dữ liệu được thu thập mỗi 10 giây/lần và lưu trữ theo <i>bucket pattern</i> (gộp theo giờ) để tối ưu truy vấn.		Dataset training cho YOLO và RAG: 20 ảnh cải bắp khỏe mạnh, 40 ảnh đốm lá, 70 ảnh thối nhũn và 50 ảnh sâu hại.

Hệ thống được thiết kế cho toàn bộ các loại rau họ cải phổ biến: Cải bắp, bông cải xanh, súp lơ, cải thảo, cải xoong và cải ngọt. Dựa trên nghiên cứu về điều kiện tối ưu cho rau họ cải [14], [15], hệ thống sử dụng các ngưỡng như được trình bày trong Bảng 3:

Bảng III: Tiêu chí đánh giá chất lượng môi trường canh tác rau họ cải

Nhiệt độ không khí				
Trạng thái	Thông số	Nội dung cảnh báo	Tác động	Trích dẫn
Tối ưu	15–21°C	Không	Phát triển tốt nhất	[14]
Cao	>27°C	Cảnh báo cao	Bông sớm, chất lượng giảm	[15]
Thấp	<10°C	Cảnh báo thấp	Chậm tăng trưởng	[14]
Độ ẩm không khí				
Tối ưu	85–95%	Không	Lá phát triển mềm mại, giòn	[14]
Thấp	<70%	Cảnh báo	Héo lá, chất lượng giảm	[14]
pH đất				
Tối ưu	6.0–7.0	Không	Hấp thu dinh dưỡng tốt	[14]
Cao	>7.5	Cảnh báo	Giảm khả năng hấp thu	[14]
Thấp	<5.5	Cảnh báo	Giảm khả năng hấp thu	[14]
Môi trường đất				
Loại	Ngưỡng tối ưu	Ngưỡng không đạt	Tác động ngưỡng ưu	Trích dẫn
N	100–150 kg/ha	<100 hoặc >150	Phát triển lá	[15]
P	40–60 kg/ha	<40 hoặc >60	Phát triển rễ	[15]
K	80–120 kg/ha	<80 hoặc >120	Sự đề kháng	[15]

D. Xử lý ảnh và trích xuất đặc trưng

1) Kiến trúc YOLO phát hiện bệnh trên cây họ cải

Hệ thống sử dụng YOLOv11 để phát hiện bệnh trên lá rau theo thời gian thực với độ chính xác cao. Ở giai đoạn tiền xử lý, ảnh được chuyển về 640×640 và áp dụng tăng cường dữ liệu như xoay ngẫu nhiên ($\pm 15^\circ$), thay đổi độ sáng ($\pm 20\%$), lật ngang và cắt-phóng ngẫu nhiên để tăng khả năng tổng quát hóa và giảm overfitting. Kiến trúc mạng gồm backbone CSPDarknet cải tiến với cơ chế CSP giảm tính toán nhưng vẫn trích xuất đặc trưng mạnh mẽ, neck PAN-FPN kết hợp thông tin đa mức tăng độ nhạy phát hiện vùng bệnh nhỏ hoặc phức tạp, và head Decoupled Head tách biệt phân loại và hồi quy vị trí cải thiện tốc độ hội tụ và độ chính xác. Quá trình huấn luyện áp dụng hàm mất mát GIOU/Focal-EIoU để xử lý trường hợp chồng lấn hoặc tỷ lệ hộp khác biệt, kết hợp mosaic augmentation, mixup và label smoothing để nâng cao khả năng tổng quát trong điều kiện ánh sáng và góc chụp đa dạng. Sau huấn luyện, mô hình được tối ưu bằng quantization và chuyển sang ONNX hoặc TensorRT để giảm dung lượng và tăng tốc suy luận trên thiết bị biên như ESP32-S3 hoặc Jetson Nano, cho phép phát hiện nhanh và chính xác bệnh lý trên rau họ cải trong thời gian thực ngay cả khi điều kiện ánh sáng, góc nhìn hoặc độ phân giải thay đổi.

Bảng IV: Kiến trúc YOLO phát hiện bệnh trên cây họ cải

Kiến trúc mô hình	Backbone: CSPDarknet53 để trích xuất features. Neck: PANet (Path Aggregation Network) để kết hợp features đa tỷ lệ. Head: Detection head với 3 output scales (80×80, 40×40, 20×20). Output: Bounding boxes + Confidence scores + Class probabilities.
Lớp phát hiện	Leaf disease (Lá bị bệnh).
Tham số huấn luyện	Optimizer: AdamW. Learning rate: 0.001 với cosine annealing. Batch size: 16. Epochs: 100. Loss function: CIoU loss + Binary Cross Entropy.
Hậu xử lý	Non-Maximum Suppression với IoU threshold 0.45. Confidence threshold: 0.5. Kết quả được gửi đến OpenAI để tạo mô tả bằng ngôn ngữ tự nhiên.

2) Kiến trúc RAG cho tư vấn chi tiết

RAG (Retrieval-Augmented Generation) kết hợp mô hình tìm kiếm tri thức và mô hình sinh ngôn ngữ, hoạt động bằng cách truy xuất thông tin và sinh ngôn ngữ tự nhiên. Khi nhận câu hỏi hoặc ngữ cảnh, hệ thống tìm kiếm tài liệu liên quan từ cơ sở tri thức thông qua truy xuất ngữ nghĩa hoặc tìm kiếm vector, sau đó cung cấp cho mô hình ngôn ngữ lớn (LLM) để tạo câu trả lời có tính ngữ cảnh cao, vừa chính xác về tri thức vừa tự nhiên trong diễn đạt. Kiến trúc RAG gồm retriever ánh xạ văn bản và câu hỏi vào không gian vector ngữ nghĩa thông qua embedding để xác định mức độ tương đồng dựa trên cosine similarity hoặc Euclidean distance, generator là mô hình ngôn ngữ lớn như GPT, BERT hoặc LLaMA tạo câu trả lời dựa trên thông tin retriever cung cấp, và knowledge base được triển khai dưới dạng cơ sở dữ liệu vector như MongoDB Atlas Vector Search hoặc FAISS.

Bảng V: Công nghệ được áp dụng trong kiến trúc RAG

Trích xuất đặc trưng	Generation	Knowledge Base
Sử dụng: VGG16 pre-trained trên ImageNet. Trích xuất features từ layer FC2 (4096 chiều). Đầu ra: Dense vector 4096-dimensional embedding.	Model: GPT-4. Prompt template bao gồm: query image description, top-K retrieved cases, context về điều kiện môi trường hiện tại. Đầu ra: Tư vấn chi tiết về bệnh, nguyên nhân, mức độ nghiêm trọng và biện pháp xử lý.	Database: MongoDB Atlas Vector Search. Chứa các embedding của văn bản, hình ảnh hoặc dữ liệu đa phương thức. Cung cấp phương thức truy vấn các tài liệu tương đồng nhất dựa trên cosine similarity hoặc Euclidean distance.

E. Phát triển phần mềm

Hệ thống giám sát và phân tích chất lượng rau họ cải được phát triển trên nền tảng điện toán đám mây AWS EC2, bảo đảm khả năng mở rộng, hiệu năng xử lý và chi phí vận hành hợp lý. Các thành phần trong hệ thống được triển khai dưới dạng dịch vụ container hóa bằng Docker, cho phép đóng gói và triển khai linh hoạt trên nhiều môi trường khác nhau. Docker Compose được sử dụng để điều phối và khởi tạo đồng thời các container, giúp tối ưu hóa quá trình quản lý và bảo trì hệ thống.

Lớp phân phối nội dung được hỗ trợ bởi Cloudflare CDN,

đóng vai trò tăng tốc độ truy cập và ổn định đường truyền, đồng thời đảm nhận chức năng DNS và tường lửa ứng dụng web (WAF) nhằm bảo đảm tính an toàn cho hệ thống. Nginx được cấu hình như một reverse proxy và load balancer, giúp phân phối lưu lượng truy cập hợp lý giữa các container, duy trì hiệu suất và độ tin cậy cao ngay cả khi có nhiều người dùng đồng thời.

Ở tầng xử lý nghiệp vụ, hệ thống áp dụng kiến trúc đa ngôn ngữ: Node.js được sử dụng cho các dịch vụ backend IoT, phụ trách thu thập, xử lý và lưu trữ dữ liệu cảm biến, cũng như điều khiển thiết bị ngoại vi (bơm, đèn chiếu sáng) dựa trên các ngưỡng môi trường được định nghĩa. Song song đó, Python đảm nhiệm các tác vụ xử lý ảnh và trích xuất đặc trưng phục vụ pipeline AI RAG (Retrieval-Augmented Generation), bao gồm nhận dạng bệnh lá bằng YOLOv11, vector hóa ảnh qua VGG16 và truy vấn tương tự trong cơ sở dữ liệu vector.

Hệ thống cơ sở dữ liệu sử dụng MongoDB Atlas theo mô hình document-oriented, hỗ trợ lưu trữ dữ liệu cảm biến, metadata hình ảnh, và vector embedding, đồng thời tận dụng bucket pattern để tối ưu hóa tốc độ truy vấn dữ liệu IoT theo thời gian. Đối với dữ liệu vector, MongoDB Vector Search được tích hợp nhằm thực hiện truy vấn tương đồng dựa trên cosine similarity, giúp rút ngắn thời gian tìm kiếm và nâng cao hiệu quả truy xuất thông tin bệnh cây.

Tầng giao diện người dùng được phát triển bằng ReactJS cho nền tảng web và React Native cho ứng dụng di động, cung cấp khả năng giám sát thời gian thực, phân tích dữ liệu trực quan và điều khiển thiết bị từ xa. Hai nền tảng này kết nối trực tiếp với backend thông qua API RESTful, giúp đảm bảo tính nhất quán dữ liệu và khả năng phản hồi nhanh.

Tổng thể, hệ thống được thiết kế theo hướng microservice kết hợp cloud-native, mang lại khả năng tự động hóa, phản hồi thời gian thực, bảo mật và dễ dàng mở rộng quy mô, đáp ứng yêu cầu triển khai trong môi trường nông nghiệp thông minh hiện đại

F. Thiết lập thực nghiệm

Để đánh giá hiệu quả của hệ thống giám sát và tư vấn chất lượng nông sản, nhóm nghiên cứu tiến hành thiết lập môi trường thực nghiệm bao gồm hạ tầng phần cứng, phần mềm và tập dữ liệu kiểm thử. Thí nghiệm được triển khai trong môi trường thực tế mô phỏng nông trại thủy canh thu nhỏ, với các thiết bị IoT được lắp đặt cố định để thu thập dữ liệu cảm biến định kỳ và ghi nhận ảnh cây trồng. Hệ thống backend được triển khai trên nền tảng AWS EC2 nhằm đảm bảo khả năng mở rộng, tính ổn định và tốc độ phản hồi trong quá trình kiểm thử.

Bảng VI: Môi trường triển khai

Môi trường phần cứng	Môi trường phần mềm	Dataset thực nghiệm
Nông trại thử nghiệm: Bể kính mica (45 × 30 × 25) Một thiết bị IoT được lắp đặt vào bể kính mica Kết nối: WiFi 2.4GHz với router trung tâm	Server: AWS EC2 t3.medium (us-west-2) OS: Ubuntu 22.04 LTS Database: MongoDB Atlas M10 cluster	Training set: 2,659 ảnh (~87.3%) Validation set: 219 ảnh (~8.2%) Test set: 118 ảnh (~5%) Thời gian thu thập: 1 tháng

Bảng VII: Các kịch bản kiểm thử


Giám sát môi trường liên tục	Phát hiện bệnh tự động (YOLO)	Tư vấn bệnh qua RAG	Stress test
Thiết bị IoT gửi dữ liệu mỗi 5 phút trong 30 ngày Kiểm tra: Tỷ lệ mất gói, độ trễ, độ chính xác của cảm biến Thông số: Uptime, data integrity, response time	100 mẫu ảnh test với các loại bệnh khác nhau Điều kiện ánh sáng: natural, cloudy, artificial Góc chụp: top-down, 45°, side view Metrics: Accuracy, Precision, Recall, F1-score, mAP	50 truy vấn với ảnh cây trồng bị bệnh So sánh kết quả RAG với chẩn đoán của chuyên gia Metrics: Accuracy, relevance score, response time	100 người dùng đồng thời truy cập hệ thống 1000 yêu cầu/phút từ IoT devices Số liệu: Thời gian phản hồi, thông lượng, tỉ lệ lỗi

Bảng VIII: Chỉ số đánh giá

Mô hình YOLO	Hệ thống RAG	Hệ thống tổng thể
Accuracy: Tỷ lệ phát hiện đúng trên tổng số mẫu Precision: TP / (TP + FP) — độ chính xác dự đoán positive Recall: TP / (TP + FN) — tỷ lệ phát hiện được các trường hợp positive F1-score: $2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$ mAP: Độ chính xác trung bình trên tất cả các classes IoU: Độ chính xác của bounding box	Retrieval Accuracy: Tỷ lệ cases liên quan được retrieve đúng Response Relevance: Đánh giá của chuyên gia (thang 1–5) Consultation Accuracy: So sánh với chẩn đoán thực tế	System Uptime: Thời gian hoạt động liên tục Response Time: Thời gian xử lý request (p50, p95, p99) Data Accuracy: Độ chính xác của dữ liệu cảm biến

III. KẾT QUẢ

A. Hiệu suất của mô hình

**Hình 4:** Bảng tổng hợp kết quả mô hình YOLO**Bảng IX: Kết quả YOLO Detection**

Thông số	Giá trị
Overall Accuracy	~88.7%
mAP@0.5	91.6%
mAP@0.5:0.95	64.7%
Inference Time	42ms/image
FPS	24

Kết quả huấn luyện mô hình YOLOv11 cho thấy quá trình hội tụ ổn định và hiệu quả. Các chỉ số mất mát (box loss, cls loss, dfl loss) giảm dần qua từng epoch, đồng thời độ chính xác và độ bao phủ (precision, recall) tăng đều, phản ánh khả năng học sâu của mô hình đối với đặc trưng hình ảnh bệnh trên rau họ cải. Sau khoảng 100 epoch, mô hình đạt trạng thái ổn định với độ chính xác tổng thể (Overall Accuracy) khoảng 88.7%, mAP@0.5 đạt 91.6%, và mAP@0.5:0.95 đạt 64.7%. Thời gian suy luận trung bình chỉ 42ms/ảnh, tương ứng tốc độ 24 FPS, đảm bảo khả năng phát hiện thời gian thực khi triển khai trong hệ thống IoT nông nghiệp.

Bảng X: Kết quả theo từng class

Class	Precision	Recall	F1-Score	Support
Diseased	82.3%	90.8%	86.3%	271

Kết quả chi tiết theo từng lớp cho thấy mô hình đạt Precision 82.3%, Recall 90.8% và F1-score 86.3% trên lớp “Diseased”, chứng tỏ mô hình nhận diện tốt các vùng lá bị bệnh ngay cả trong điều kiện ánh sáng và góc chụp khác nhau. Ma trận nhầm lẫn (Confusion Matrix) cũng thể hiện khả năng phân biệt rõ ràng giữa hai lớp “Diseased” và “Background”, với tỷ lệ dự đoán chính xác cho lớp bị bệnh đạt 91%, cho thấy mức độ khái quát hóa tốt của mô hình trên tập kiểm thử.

Mô hình YOLOv11 đạt hiệu năng cao cả về độ chính xác lẫn tốc độ, phù hợp để tích hợp vào pipeline giám sát tự động trong nông nghiệp. Việc kết hợp mô hình này với hệ thống RAG và IoT giúp tối ưu hóa quy trình phát hiện bệnh, cung cấp cảnh báo sớm và hỗ trợ ra quyết định cho người trồng trọt một cách hiệu quả.


Bảng XI: Kết quả RAG System

Thông số	Giá trị
Retrieval Accuracy	92.0%
Top-1 Accuracy	85.0%
Top-5 Accuracy	96.0%
Response Time	2.3s
Expert Agreement	88.5%

Hệ thống RAG (Retrieval-Augmented Generation) hỗ trợ tư vấn nguyên nhân và biện pháp xử lý bệnh cây trồng thông qua truy xuất tri thức kết hợp sinh ngôn ngữ tự nhiên. Kết quả thực nghiệm đạt Retrieval Accuracy 92.0% chứng tỏ khả năng truy tìm chính xác các trường hợp tương tự, với Top-1 Accuracy 85.0% và Top-5 Accuracy 96.0% thể hiện tính nhất quán và khả năng hiểu ngữ cảnh trong truy vấn bệnh lý thực vật. Thời gian phản hồi trung bình 2.3 giây đáp ứng tốt yêu cầu tương tác thời gian thực, trong khi mức độ đồng thuận với chuyên gia đạt 88.5% cho thấy kết quả từ GPT-4 không chỉ hợp lý về ngữ nghĩa mà còn phù hợp thực tế canh tác. Điều này chứng minh hiệu quả của cơ chế kết hợp LLM và MongoDB Atlas Vector Database, giúp RAG tái hiện thông tin chính xác và cung cấp giải thích chuyên sâu giàu ngữ cảnh. Nhìn chung, hệ thống RAG thể hiện khả năng tư vấn bệnh hại thông minh, thuyết phục và dễ hiểu, đóng vai trò quan trọng trong pipeline chẩn đoán-khuyến nghị tự động cho mô hình giám sát nông nghiệp thông minh.


B. Giao diện và tính năng hệ thống

Hình 4 là giao diện tổng quan của hệ thống, hiển thị các thông số môi trường theo thời gian thực, cảnh báo nồng độ dinh dưỡng vượt ngưỡng, thanh công cụ quản lý thiết bị và nông sản, chức năng lọc lịch sử thu hoạch và xuất dữ liệu Excel, cùng lịch theo dõi hoạt động canh tác theo tháng.



Hình 5: Giao diện tổng quan

Màn hình kiểm tra tình trạng nông sản tự động cho phép người dùng xem kết quả chẩn đoán tình trạng cây trồng do hệ thống AI thực hiện dựa trên hình ảnh được thu thập định kỳ từ thiết bị IoT. Người dùng có thể lọc dữ liệu theo thời gian, xem ảnh thực tế và ảnh chẩn đoán của từng mẫu cây, cùng với kết luận AI về tình trạng sức khỏe của cây. Chức năng này giúp nông dân theo dõi diễn biến sinh trưởng, phát hiện sớm bệnh hại, và ra quyết định chăm sóc kịp thời mà không cần giám sát thủ công.



Hình 6: Giao diện kiểm tra tình trạng nông sản tự động

IV. THẢO LUẬN

A. Phân tích kết quả

Hệ thống đạt độ chính xác trung bình 88.7% trên 100 mẫu, cao hơn nhiều so với phương pháp thủ công (70%). Mô hình YOLO cho kết quả F1-score 86.3%, trong khi kiến trúc RAG đạt 92% độ chính xác truy xuất và 88.5% mức độ đồng thuận chuyên gia, thể hiện năng lực tư vấn tin cậy. Mô hình VGG16 pre-trained cho phép trích xuất đặc trưng hiệu quả trên tập dữ liệu nhỏ, còn MongoDB Vector Search với cosine similarity tìm kiếm nhanh trong 95 ms. Sai số đo đặc chủ yếu do cảm biến DHT11 và ES-SOIL-7-IN-1, cần hiệu chuẩn định kỳ. Cấu trúc lưu trữ bucket pattern giúp giảm 80% số lượng tài liệu, tăng tốc độ truy vấn. YOLO inference chỉ mất 45 ms/ảnh, bảo đảm phản hồi thời gian thực. Nhờ Docker và hạ tầng cloud, hệ thống dễ dàng mở rộng và triển khai trên quy mô lớn.

B. Hạn chế

Hệ thống còn một số hạn chế cần khắc phục. Hiệu suất model giảm đáng kể trong điều kiện ánh sáng kém, với độ chính xác giảm từ 88.7% xuống 82.5% khi ánh sáng dưới 100 Lux ở buổi tối hoặc trời mưa, có thể khắc phục bằng cách bổ sung đèn LED tự động khi chụp ảnh hoặc train thêm với augmented data ở điều kiện ánh sáng thấp. Dataset hiện tại tập trung vào 5 loại bệnh phổ biến, nên với bệnh hiếm hoặc biến thể mới model có thể cho kết quả không chính xác, cần liên tục thu thập và retrain model với dữ liệu mới thông qua hợp tác của nhiều nông trại và chuyên gia. RAG pipeline mất 1.5s do gọi OpenAI API, với số lượng request lớn chi phí cao và latency tăng, có thể giải quyết bằng cache các câu hỏi phổ biến hoặc sử dụng local LLM như Llama 2 để giảm dependency và chi phí.

C. Ứng dụng thực tiễn

Hệ thống được áp dụng xuyên suốt chuỗi cung ứng nông sản từ sản xuất đến tiêu thụ. Ở giai đoạn sản xuất, nông dân theo dõi tình trạng cây trồng theo thời gian thực để phát hiện sớm sâu bệnh hoặc vấn đề dinh dưỡng, giảm thiểu tổn thất và đảm bảo chất lượng, đồng thời toàn bộ quá trình canh tác được ghi nhận tự động tạo hồ sơ minh bạch. Trong giai đoạn thu mua, nhà phân phối truy cập dữ liệu chất lượng nông sản để đàm phán giá minh bạch và giảm tranh chấp. Đến giai đoạn tiêu thụ, người tiêu dùng quét mã QR kiểm tra nguồn gốc, quá trình trồng trọt và chứng nhận chất lượng, tăng niềm tin và sẵn sàng chi trả cao hơn, góp phần xây dựng thương hiệu nông sản Việt. Đối với nông dân, hệ thống giúp tiếp cận thị trường cao cấp nhờ chứng nhận và truy xuất nguồn gốc rõ ràng, đồng thời giảm áp lực công việc nhờ tự động hóa và gợi ý thông minh. Doanh nghiệp được đảm bảo nguồn cung ổn định, giảm rủi ro nhập hàng kém chất lượng, xây dựng thương hiệu bền vững và tối ưu logistics nhờ dự đoán năng suất và thời điểm thu hoạch, đáp ứng tốt yêu cầu kiểm định và xuất khẩu. Trên bình diện xã hội, hệ thống thúc đẩy nông nghiệp bền vững, giảm phụ thuộc hóa chất, đảm bảo an toàn thực phẩm, tạo chuỗi cung ứng minh bạch và công bằng, tăng niềm tin giữa các bên, đồng thời thu hút thế hệ trẻ tham gia phát triển nông nghiệp thông minh và hiện đại hóa nông thôn Việt Nam.

TÀI LIỆU THAM KHẢO

TÀI LIỆU

- [1] K. A. Patil and N. R. Kale, "A Model for Smart Agriculture Using IoT," in *2016 International Conference on Global Trends in Signal Processing, Information Computing and Communication (ICGTSPICC)*, Jalgaon, India, 2016, pp. 543–545.
- [2] N. Sakthipriya, "An Effective Method for Crop Monitoring Using Wireless Sensor Network," *Middle-East Journal of Scientific Research*, vol. 20, no. 9, pp. 1127–1132, 2014.
- [3] I. Mat, M. R. M. Kassim, A. N. Harun, and I. M. Yusoff, "IoT in Precision Agriculture Applications Using Wireless Moisture Sensor Network," in *2016 IEEE Conference on Open Systems (ICOS)*, Langkawi, Malaysia, 2016, pp. 24–29.
- [4] S. Zafar, G. Miraj, R. Baloch, W. Murtaza, and A. Arshad, "An IoT-based Real-Time Environmental Monitoring System Using Arduino and Cloud Service," *Engineering, Technology & Applied Science Research*, vol. 8, no. 4, pp. 3238–3242, 2018.
- [5] A. Tzounis, N. Katsoulas, T. Bartzanas, and C. Kittas, "Internet of Things in Agriculture: Recent Advances and Future Challenges," *Biosystems Engineering*, vol. 164, pp. 31–48, 2017.
- [6] K. N. Siddiquee and S. R. Hossain, "Detection and Quantification of Vegetables Using Deep Learning," in *2022 IEEE Region 10 Symposium (TENSYP)*, Mumbai, India, 2022, pp. 1–6.
- [7] R. Sharma, A. Kukreja, and M. Sharma, "Detection and Classification of Fruits and Vegetables Diseases Using Deep Learning Technique," in *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*, Tirunelveli, India, 2021, pp. 1289–1294.
- [8] J. Liu and X. Wang, "Tomato Diseases and Pests Detection Based on Improved YOLOv3 Convolutional Neural Network," *Frontiers in Plant Science*, vol. 11, p. 898, 2020.
- [9] Y. Li *et al.*, "YOLO-LeafNet: An Efficient and Accurate Deep Learning Model for Leaf Disease Detection," *Computers and Electronics in Agriculture*, vol. 205, p. 107633, 2023.
- [10] M. Atila, M. Hilal, and D. Atila, "Plant Leaf Disease Classification Using EfficientNet Deep Learning Model," *Ecological Informatics*, vol. 61, p. 101182, 2021.
- [11] P. Lewis *et al.*, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- [12] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, and H. Wang, "Retrieval-Augmented Generation for Large Language Models: A Survey," *arXiv preprint arXiv:2312.10997*, 2023.
- [13] A. Ramesh, S. K. Khillar, A. Gupta, and V. K. Verma, "AgriBot: An AI-Powered Chatbot for Crop Advisory Using RAG Architecture," in *2023 International Conference on Machine Intelligence and Smart Systems (MISS)*, Coimbatore, India, 2023, pp. 1–6.
- [14] R. Lal, "Soil Science and Food Security: Challenges in the 21st Century," *Soil Science Society of America Journal*, vol. 84, no. 4, pp. 1027–1042, 2020.
- [15] J. R. Hanson and G. R. Dixon, "Brassica Crops," in *Encyclopedia of Applied Plant Sciences*, 2nd ed., Academic Press, 2017, pp. 358–366.